

1. 서론

1.1 연구 배경

거대 언어 모델(LLM, Large Language Model)의 성능을 결정하는 가장 핵심적인 요소는 학습에 사용되는 말뭉치의 품질이다. 아무리 우수한 모델 아키텍처와 학습 알고리즘을 사용하더라도, 저품질의 데이터로 학습된 모델은 실제 환경에서 성능을 발휘하기 어렵다. 특히 한국어 자연어처리 분야에서는 영어 대비 상대적으로 고품질 데이터가 부족하고, 언어의 교착어적 특성과 형태론적 복잡성으로 인해 데이터 품질 관리가 더욱 중요하다.

산업 현장에서 특정 태스크에 맞는 대규모 한국어 텍스트 데이터를 수집하고 구축하는 과정에서는 다양한 형태의 휴먼 에러가 불가피하게 발생한다. 수십만에서 수백만 건에 달하는 데이터를 구축하는 과정에서 작업자의 실수나 시스템 오류는 빈번하게 일어나며, 이러한 오류들이 누적되면 학습 데이터의 품질을 저하시키고 최종적으로 모델의 성능에 부정적인 영향을 미친다.

한국어 텍스트 입력 과정에서 발생하는 오류의 대부분은 편집 거리 1 이내의 단순 오타에서 기인하며, 이는 크게 삽입(Insertion), 삭제(Deletion), 대치(Substitution)의 세 가지 유형으로 분류된다¹⁾. 특히 한국어는 자음과 모음이 결합하여 음절을 이루는 교착어적 특성을 가지고 있어, 오류가 음절 단위와 자소 단위 모두에서 발생할 수 있다. 현재 BERT 계열 모델에서 주로 사용되는 서브워드 토큰나이저는 이러한 오타자가 포함된 텍스트를 원래 의도된 의미 단위대로 분해하지 못하고, 개별 문자나 [UNK] 토큰들로 쪼개게 된다. 이러한 토큰나이징 오류는 모델이 각 단어의 의미를 올바르게 파악하는 것을 방해하며, 이러한 오류가 빈번할 경우 모델이 학습해야 할 목표 자체가 왜곡되어 치명적인 성능 저하를 초래할 수 있다.

본 실험에서는 데이터 구축 현장에서 가장 빈번하게 발생하는 오류 유형 중 삽입 오류와 삭제 오류를 다룬다. 삭제 오류는 원본 텍스트의 일부 내용이 누락되는 현상으로, 작업자가 텍스트를 복사-붙여넣기하는 과정에서 일부 문장을 놓치거나, 문서 스캔 시 일부 영역이 인식되지 않거나, 데이터 전송 과정에서 일부 내용이 손실되는 경우가 이에 해당한다. 삽입 오류는 원본 텍스트에 존재하지 않던 문자나 기호가 추가되는 현상으로, 타이핑 과정에서 의도하지 않은 문자가 입력되거나 OCR 과정에서 노이즈 문자가 생성되는 경우가 이에 해당한다.

특히 기계독해와 같이 질문-지문-정답의 구조를 가진 태스크에서는 오류가 발생하는 위치에 따라 모델 성능에 미치는 영향이 크게 달라질 수 있다. 지문에 오류가 발생하는 경우는 입력 노이즈로 작용하지만, 정답 라벨 자체에 오류가 발생하는 경우는 모델이 학습해야 할 목표 자체를 왜곡시켜 더 치명적인 결과를 초래할 수 있다. 예를 들어, 지문에 오타가 있더라도 모델은 주변 문맥을 통해 해당 단어의 의미를 유추할 수 있지만, 정답 라벨이 잘못되면 모델은 잘못된 방향으로 파라미터를 업데이트하며 학습 방향 자체가 틀어지게 된다.

AI Hub에서 제공하는 행정 문서 기계독해 데이터와 같이 공공 분야에서 구축된 데이터셋은 엄격한 품질 관리를 거쳐 비교적 높은 수준의 정확도를 유지하고 있다. 그러나 실제 산업 현장에서 단기간에 대규모로 구축되는 데이터는 위와 같은 삽입 및 삭제 오류에 노출될 가능성이 상당히 높다.

²⁾NIA(National Information Society Agency)는 「생성형 AI 데이터 품질관리 가이드 v2.0」을 통해 유효성을 핵심 품질 지표로 제시하고 있다. 유효성은 AI 모델을 학습용 데이터로 훈련한 후 측정된 성능이 실제로 유효한지를 평가하는 품질특성으로, 데이터의 품질이 모델 성능에 직접적인 영향을 미친다는 점을 강조한다. 이는 단순히 데이터의 형식적 완결성을 넘어, 실제로 모델이 해당 데이터로부터 올바른 패턴을 학습할 수 있는지를 중요하게 고려해야 함을 의미한다.

그러나 현장에서는 제한된 시간과 예산 내에서 모든 품질 요소를 완벽하게 관리하기 어렵다. 데이터 구축 프로젝트에서는 통상적으로 데이터 수량, 구축 기간, 예산이 사전에 정해져 있으며, 이러한 제약

1) 구선민, 박찬준, 소아람, 임희석. (2021). 딥러닝 기반 한국어 맞춤법 교정을 위한 오류 유형 분류 및 분석. 한국융합학회논문지

2) NIA, 2025년 AI 데이터 품질관리 가이드라인 v3.5

조건 하에서 최대한의 품질을 확보해야 한다. 따라서 어떤 유형의 데이터 품질 저하가 모델 성능에 더 큰 영향을 미치는지를 정량적으로 파악하는 것이 중요하다.

하지만 현재까지 한국어 기계독해 데이터를 대상으로 지문과 정답의 오류 위치와 종류별 영향력을 체계적으로 비교 분석한 연구는 부족한 실정이다. 특히 삽입 오류와 삭제 오류가 발생하는 위치와 빈도에 따라 모델 성능이 어떻게 달라지는지에 대한 정량적 분석이 필요하며, 이를 통해 한정된 검수 인력과 시간을 어느 부분에 어느 정도로 배분해야 하는지에 대한 실무적 가이드라인이 요구된다.

1.2 연구 목적

본 연구는 한국어 기계독해 데이터를 활용한 질의응답(QA) 태스크를 대상으로, 데이터 품질 저하의 세 가지 주요 요인이 모델 성능에 미치는 영향을 체계적으로 분석하고자 한다. 구체적으로 '데이터 결측률', '구문 정확성', '라벨링 정확성'이라는 세 가지 변인을 독립적으로 조작하여, 각 요인이 KLUE-BERT 기반 한국어 기계독해 모델의 성능에 미치는 영향을 정량적으로 측정한다.

본 연구에서는 AI Hub의 행정 문서 기계독해 데이터셋을 활용한다. 원본 데이터는 고품질이 보장된 데이터이므로, 실제 현장에서 발생 가능한 오류 상황을 실험 환경에서 재현하기 위해 세 가지 유형의 인위적 오염을 적용한다. 데이터 결측률은 지문 내 일부 토큰의 삭제를 통해, 구문 정확성은 지문 내 특수문자 삽입을 통해, 라벨링 정확성은 정답 라벨 내 특수문자 삽입을 통해 구현한다. 이러한 실험 설계를 통해 오류의 유형과 발생 위치에 따른 모델 성능 변화를 체계적으로 비교 분석한다.

이를 통해 본 연구는 다음과 같은 질문에 답하고자 한다:

1. 지문 내 정보의 부재가 모델의 문맥 이해 능력에 미치는 영향은 어느 정도인가?
2. BERT의 사전학습 기반 강건성은 지문 내 오탈자에 대해 어느 정도 유효한가?
3. 정답 라벨의 오염에 따른 잘못된 토큰나이징은 어느 정도의 성능 저하를 야기하는가?
4. 오류 유형 및 발생 위치에 따른 성능 저하 정도의 차이를 바탕으로, 데이터 품질 검수의 우선순위를 어떻게 설정해야 하는가?

최종적으로 본 연구는 실험 결과를 바탕으로 데이터 전처리 및 품질 검수 단계에서 어떤 요소에 우선적으로 자원을 투입해야 하는지에 대한 가이드라인을 제시하고자 한다. 본 연구의 결과는 향후 대규모 한국어 AI 학습 데이터 구축 프로젝트에서 효율적인 품질 관리 전략을 수립하는 데 기여할 것으로 기대한다.

2. 실험 설계

2.1 주요 품질 저하 요인 정의

본 연구에서는 실제 데이터 구축 현장에서 발생 가능한 세 가지 핵심 품질 저하 요인을 정의하고, 각 요인이 모델 학습에 미치는 영향을 독립적으로 측정하기 위한 실험적 조작 방법을 구체화한다. 세 가지 요인은 각각 데이터 결측률, 구문 정확성, 라벨링 정확성으로 나타낼 수 있으며, 기계독해 태스크의 서로 다른 측면에 영향을 미친다.

2.1.1 데이터 결측률

$$\text{데이터 결측률(\%)} = \left(\frac{(\text{일부 단어가 누락된 레코드 수})}{(\text{전체 레코드 수})} \right) \times 100$$

데이터 결측률은 기계독해 태스크에서 지문 내 정보가 물리적으로 누락된 비율을 의미한다. 이는 데이터 입력 과정에서 일부 텍스트가 복사되지 않거나, 문서 스캔 과정에서 일부 내용이 손실되거나, 작업자의 부주의로 인해 문장 일부가 누락되는 등의 상황을 의미한다.

측정 방법: 전체 데이터 레코드 중 정답이 포함되지 않은 문장에서 토큰이 누락된 레코드의 비율을 측정한다. 정답이 포함된 문장은 제외하여, 결측 자체보다는 문맥 정보의 손실이 모델 성능에 미치는

순수한 영향을 측정한다.

배경: 기계독해 모델은 QA 태스크에서 주어진 지문을 읽고 질문에 대한 정답을 추론한다. 만약 지문에서 일부 정보가 누락되면, 모델이 문맥을 완전히 이해하지 못해 추론 능력이 저하될 수 있다. 특히 누락된 단어가 문맥의 핵심 정보를 담고 있는 경우, 모델은 질문에 답하기 위한 충분한 정보를 얻지 못할 수 있다.

구현 방법: 전체 문장을 구성하는 토큰 중 불용어와 정답 토큰을 제외한 일반 토큰의 15%를 무작위로 선택하여 삭제한다. 불용어는 '은', '는', '이', '가'와 같이 문법적 기능만을 수행하는 조사로, 삭제되더라도 핵심 의미 전달에는 큰 영향이 없다. 정답 토큰을 제외하는 이유는 정답 자체의 결측이 아닌, 문맥 정보의 결측이 모델에 미치는 영향을 순수하게 측정하기 위함이다.

이 조작을 통해 모델이 파인튜닝 시 해당 위치에 단어가 존재했다는 사실 자체를 알지 못하게 하여, 정보 손실 시나리오를 구현한다. 모델은 불완전한 문맥 정보를 바탕으로 추론해야 하므로, 성능이 소폭 하락할 것으로 예상된다.

예시:

정상 지문: "생활폐기물은 관할 지방자치단체장이 처리한다."

오염 지문: "은 관할 지방자치단체장이 처리한다."

질문: 생활폐기물 처리 주체는?

정답: 관할 지방자치단체장

위 예시에서 '생활폐기물'이라는 핵심 명사가 삭제되었지만, 정답인 '관할 지방자치단체장'은 여전히 존재하므로, 모델은 불완전한 문맥으로도 정답을 찾을 가능성이 있다. 그러나 지문의 의미가 불완전해져 문맥 이해 능력이 요구되는 복잡한 질문에서는 성능 저하가 발생할 수 있다.

2.2 구문 정확성

$$\text{구문 정확성 (\%)} = \left(1 - \frac{(\text{구문 오류(오타자)가 포함된 레코드 수})}{(\text{전체 레코드 수})}\right) \times 100$$

구문 정확성은 정답이 아닌 지문 텍스트의 오타자 및 문법적 오류 수준을 나타낸다. 이는 데이터 입력 과정에서 작업자의 타이핑 실수, OCR 오류, 또는 문서 변환 과정에서 발생하는 오류 중 삽입(Insertion) 유형에 해당하는 오류를 시뮬레이션한다.

측정 방법: 데이터 생성 과정 중 정답이 아닌 단어에 오타자가 발생한 레코드의 비율을 측정한다. 이는 토큰라이저가 단어 중간의 오타자로 인하여 단어를 잘못된 의미 단위(Subword)로 분해하도록 유도하는 노이즈 상황을 가정한다.

배경: BERT 계열 모델은 사전학습 단계에서 마스크 언어 모델링(MLM, Masked Language Modeling) 과제를 통해 훈련된다. MLM은 입력 문장의 일부를 가리고 주변 문맥을 통해 이를 복원하는 방식이므로, 모델은 태생적으로 불완전한 정보나 노이즈에 대한 내성(Robustness)을 갖게 된다. 따라서 지문에 오타자가 포함되더라도, 정답 토큰이 온전하다면 모델이 문맥을 추론하여 성능 저하를 어느 정도 방어할 수 있을 것으로 예상된다.

구현 방법: 지문 내 정답 토큰이 아닌 텍스트 사이에 무작위 특수문자(!, @, #, \$, %, ^, &, *)를 1~3개 선택하여 전체 토큰의 10%, 20%, 30%에 해당하는 위치에 삽입한다. 특수문자는 토큰라이저가 단어를 잘못 분해하도록 유도하여, 원래의 의미 단위가 파괴되는 효과를 발생시킨다.

이를 통해 지문에 노이즈가 존재하는 환경에서 BERT의 사전학습된 강건성이 어느 정도 유효한지를 검증한다.

예시:

정상 지문: "생활폐기물은 관할 지방자치단체장이 처리한다."

오염 지문 (지문 내 오타자): "생@활폐기%물은 관할 지방자치단체장이 처리한다."

질문: 생활폐기물 처리 주체는?

답변: 관할 지방자치단체장

위 예시에서 토큰라이저는 '생활폐기물'이라는 단어를 [생활] + [폐기물]로 인식하지 못하고, [생] + [@] + [활] + [폐기] + [%] + [물]로 인식하게 된다. 그러나 정답인 '관할 지방자치단체장'은 여전히 정상적으로 분해되므로, 모델은 노이즈가 있는 문맥에서도 정답을 찾을 가능성이 있다.

2.3 라벨링 정확성

$$\text{라벨링 정확성 (\%)} = \left(1 - \frac{(\text{정답 라벨에 오류가 존재하는 레코드 수})}{(\text{전체 레코드 수})} \right) \times 100$$

라벨링 정확성은 모델이 예측해야 할 정답 자체의 정확도를 의미한다. 기계독해 태스크에서 정답은 모델이 학습해야 할 목표 출력이므로, 정답에 오류가 포함되면 모델은 잘못된 패턴을 학습하게 된다.

측정 방법: 정답 텍스트에 오타가 발생해 토큰라이저가 정답을 올바르게 분류하지 못하는 레코드의 비율을 측정한다. 이 경우 토큰라이저가 어떤 토큰이 정답 토큰인지 정확히 이해하지 못해, 모델에 심각한 수준의 학습 효율 저하가 예상된다.

이론적 배경: 질문과 명확한 답이 존재하는 지도학습에서 모델은 입력과 정답 쌍을 통해 학습한다. 정답 라벨이 정확하지 않으면 모델은 잘못된 방향으로 파라미터를 업데이트하게 되어 학습이 제대로 이루어지지 않는다.

특히 기계독해 태스크에서는 정답 텍스트의 시작 위치와 끝 위치가 주어지더라도, 정답 텍스트가 토큰나이징 오류로 인해 잘못 분해되면 모델이 해당 위치에 어떤 의미 단위의 단어가 존재하는지, 어디서부터 어디까지가 하나의 정답을 구성하는지를 올바르게 학습할 수 없다. 즉, 위치 정보는 제공되지만 그 위치에 있는 토큰들이 의미론적으로 올바른 정답을 나타내지 못하게 되는 것이다.

구현 방법: 정답 텍스트 사이에 무작위 특수문자(!, @, #, \$, %, ^, &, *)나 공백을 전체 정답의 10%, 20%, 30%에 해당하는 개수만큼 삽입한다. BERT의 서브워드 기반 토큰라이저는 단어 사이에 특수문자가 들어가면 단어를 제대로 분해하지 못하고 다른 토큰들의 조합으로 인식하므로, 정답의 의미 단위를 파악하는 과정에서 오류가 발생한다.

이 조작을 통해 모델은 정답 파손 시나리오에 노출되며, 상당한 수준의 학습 효율 저하가 예상된다. 정답의 위치 정보는 주어지지만 해당 위치의 토큰들이 잘못 분해되어 있어 모델은 어떤 의미 단위가 정답인지를 학습할 수 없으므로, 세 가지 요인 중 가장 심각한 성능 저하를 보일 것으로 예상된다.

예시:

질문: 생활폐기물 처리 주체는?

정상 지문: "생활폐기물은 관할 지방자치단체장이 처리한다."

오염 지문: "생활폐기물은 관!할 지방자@치단체장이 처리한다."

위 예시에서 정답의 시작과 끝 위치는 정상적으로 주어지지만, 토큰라이저는 정답을 [관할] + [지방자치]

+ [단체장]으로 인식하지 못하고 [관] + [!] + [할] + [지방] + [자] + [@] + [치] + [단체장]으로 분해한다. 모델은 "관할 지방자치단체장"이라는 의미를 학습해야 하지만, 토큰들이 잘못 분해되어 있어 어떤 단어 조합이 정답을 구성하는지, 각 토큰이 정답에서 어떤 의미적 역할을 하는지를 올바르게 파악할 수 없다. 이는 모델이 정답의 패턴을 제대로 학습하지 못하게 만들어 치명적인 성능 저하를 발생시킬 것으로 예상된다.

3. 실험 설계

3.1 실험 환경

본 연구는 대규모 언어 모델의 미세 조정(Fine-tuning) 및 추론 효율성을 확보하기 위해 고성능 GPU 기반의 컴퓨팅 환경에서 수행되었다. 하드웨어로는 NVIDIA RTX A6000과 AMD Radeon RX 9070xt를 사용하였으며, 특히 AMD GPU 환경에서는 ROCm(Radeon Open Compute) 플랫폼을 활용하여 PyTorch 프레임워크 상에서 CUDA 가속을 지원, 안정적인 학습 파이프라인을 구축하였다. 소프트웨어 스택은 HuggingFace의 Transformers 라이브러리를 기반으로 구성하였다.

- GPU: NVIDIA RTX A6000 (48GB), AMD Radeon RX 9070xt (w/ ROCm)
- OS: Ubuntu 22.04 LTS, Red Hat Enterprise Linux 9.6
- Framework: PyTorch 2.x
- Library: HuggingFace Transformers, Datasets
- Model: klue/bert-base (한국어 구문 분석 및 문맥 이해를 위해 KLUE 벤치마크 데이터셋으로 사전 학습된 모델)
- Tokenizer: BertTokenizerFast (해당 모델에서 사용되는 연산 속도가 최적화된 WordPiece 기반의 Subword 토큰나이저)

3.2 모델 아키텍처

기계독해 태스크 수행을 위해 한국어에 특화된 사전 학습 모델인 KLUE-BERT를 베이스 모델로 선정하고, 출력단에 선형 분류층을 결합하여 추출형 QA 모델을 구성하였다.

입력 임베딩(Input Embedding): 질문(Question)과 지문(Context)을 단일 시퀀스로 처리하기 위해 각 토큰을 [CLS] Question [SEP] Context [SEP] 형식으로 결합하여 입력한다. 이때 각 토큰은 Token Embedding, Segment Embedding, Position Embedding의 합으로 표현된다.

인코더(BERT): 입력된 시퀀스는 다층의 Transformer Encoder를 통과하며 문맥 정보가 반영된 고차원의 임베딩 벡터로 변환된다.

출력층(Output Layer): 인코더의 마지막 은닉 상태 벡터에 선형 변환을 적용하여, 지문 내 각 토큰이 정답의 시작 위치일 확률과 끝 위치일 확률을 각각 산출한다. 학습 과정에서는 Cross-Entropy Loss를 사용한다.


3.3 데이터셋

본 실험에서는 공공 행정 분야의 기계독해 성능을 평가하기 위해 AI Hub의 '행정 문서 기계독해 데이터'를 활용하였다.³⁾ 모든 데이터는 KorQuad 1.0 포맷에 맞춰 파싱 및 가공하였으며, 실험 목적에 따라 다음과 같이 두 그룹으로 분류하여 데이터셋을 구축하였다.

대조군: AI Hub에서 가져온 원본 데이터셋. 전문가의 검수를 거친 고품질 데이터로, 모델의 대조군(Baseline) 성능을 측정하는 기준으로 사용된다.

실험군: 대조군에 본 연구에서 정의한 3가지 품질 저하 요인(데이터 결측, 구문 정확성 저하, 라벨링

3) <https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=569>



정확성 저하)을 각각 주입하여 생성한 데이터셋이다. 이를 통해 각 오류 유형이 모델 성능에 미치는 영향을 정량적으로 분석한다.

3.4 학습 설정

모델 학습을 위한 하이퍼파라미터는 모든 실험에 동일하게 적용하였다. 구체적인 설정 값은 다음과 같다.

Optimizer: AdamW (Weight Decay=0.01)

Learning Rate: $3e-5$

Batch Size: 16

Epochs: 3

Precision: BFloat16 (Mixed Precision)

3.5 평가 지표

모델의 일반화 성능을 객관적으로 검증하기 위해, 학습 데이터와 분리된 별도의 검증 데이터셋(Validation Set)을 사용하여 평가를 수행하였다. 데이터셋 분할은 AI Hub에서 제공하는

원본대로 진행하였으며, 학습 데이터셋 197,698건, 검증 데이터셋 37,042건의 질의응답(QA) 쌍을 사용하였다. 본 연구에서는 기계독해 태스크의 표준 평가 지표인 F1 Score와 EM(Exact Match)을 활용하여 모델 성능을 다각도로 분석하였다.

F1 Score

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

정답과 예측된 정답 간의 토큰 단위 중첩 정도를 측정하는 지표이다. 정답의 완벽한 일치보다는 의미적 유사성을 평가하며, 부분 점수를 반영한다.

EM (Exact Match)

$$EM = \frac{1}{N} \sum_{i=1}^N \delta(Prediction_i, GroundTruth_i)$$

모델이 예측한 정답 텍스트가 실제 정답(Ground Truth)과 문자열 수준에서 완전히 일치하는지 평가하는 지표이다. 이를 통하여 정답 추출의 정확성을 검증한다.

본 연구에서는 이 두 지표를 상호 보완적으로 사용하여, 데이터 품질 저하가 모델의 정밀한 추출 능력(EM)과 문맥적 이해 능력(F1)에 미치는 영향을 종합적으로 분석한다.

4. 실험 결과 (Results)


본 절에서는 세 가지 품질 저하 요인이 모델 성능에 미친 영향을 정량적으로 분석한다. 각 실험군별로 F1 Score와 EM을 측정하여, 대조군 대비 성능 변화를 비교한다.

4.1 데이터 결측률에 따른 성능 변화

가설: 지문 내 정보 결측(10, 20, 30%의 토큰 삭제)이 발생하면, 모델이 문맥을 완전히 이해하지 못해 추론 능력이 저하될 것이다. 그러나 정답 토큰 자체는 보존되므로, 성능 저하는 소폭에 그칠 것으로 예상된다.

실험 결과:

	F1	EM
baseline	81.41	71.99
deletion_10	81.50	71.98
deletion_20	79.18	69.07
deletion_30	77.85	67.48



데이터 결측률이 증가함에 따라 모델 성능은 완만한 하락세를 보였으나, 다른 요인에 비해 그 폭이 매

우 제한적이었다. 오염 비율이 10%일 때는 F1 Score가 81.50%를 기록하여 대조군(81.41%)과 오차 범위 내에서 동등한 수준을 유지하였으며, 30%까지 증가하더라도 77.85%를 기록하여 총 3.56%p의 하락폭에 그쳤다.

이는 "정답 토큰이 보존되므로 성능 저하가 소폭에 그칠 것"이라는 가설에 부합하는 결과이다. 실험 결과는 지문 내 정보가 일부(최대 30%) 누락되더라도, 모델이 남은 문맥 정보를 활용하여 충분히 정답을 도출할 수 있음을 시사한다. 즉, 기계독해 지문의 특성상 지문에 정보의 중복성이 다수 존재하여, 일부 단어가 삭제되더라도 모델의 추론 메커니즘이 크게 훼손되지 않음을 확인하였다. EM(Exact Match) 역시 71.99%에서 67.48%로 약 4.5%p 하락하는 데 그쳐, 문맥 정보가 일부 소실돼도 정답 추출의 정확도에 치명적인 영향을 주지 않음을 입증하였다.


결론: 데이터 결측률은 모델 성능에 제한적인 영향을 미쳤으며, 오염 비율이 증가하더라도 성능 하락폭은 미미한 수준에 그쳤다. 따라서 데이터 구축 시 지문의 완전성 확보에 과도한 자원을 투입하기보다는, 모델 성능에 직결되는 정답 라벨과 질문의 완전성을 확보하는 데 자원을 우선 배분하는 것이 효율적일 것으로 사료된다.

4.2 구문 정확성 저하에 따른 성능 변화

가설: 지문 내 오타자(특수문자 삽입)가 발생하더라도, BERT는 MLM(Masked Language Modeling) 사전학습을 통해 노이즈에 대한 일정 수준의 복원력과 강건성을 확보했으므로, 성능 저하는 미미할 것으로 예상된다.

실험 결과:

	F1	EM
baseline	81.41	71.99
insertion_que_10	74.53	65.06
insertion_que_20	60.15	50.89
insertion_que_30	44.29	36.65



분석: 구문 정확성 저하는 당초 예상과 달리 모델 성능에 상당한 수준의 부정적 영향을 미치는 것으로 확인되었다. 오염 비율이 10%일 때 F1 Score는 74.53%로 대조군 대비 6.88% 하락하였으나, 오염도가 30%로 증가함에 따라 44.29% 급격히 하락하며 총 37.12%의 심각한 성능 저하를 기록하였다.

이는 "BERT의 MLM 사전학습 효과로 인해 노이즈에 어느 정도 강건할 것"이라는 초기 가설을 반증하는 결과이다. 이러한 성능 붕괴의 주된 원인은 본 실험에 사용된 서브워드(Subword) 기반 토큰라이저의 구조적 취약점에 기인한다. WordPiece와 같은 알고리즘은 단어를 의미 있는 최소 단위(Subword)로 분절하여 임베딩을 생성하는데, 텍스트 내에 삽입된 무작위 특수문자는 이 분절 과정을 강제로 교란시킨다. 예를 들어, '지방자치단체'라는 핵심 키워드에 특수문자가 삽입되어 '지방#자&치단@체'로 변형될 경우, 토큰라이저는 이를 [지방] + [자치] + [단체]라는 의미 단위가 아닌 [지방] + [#] + [자] + [&] + [치단] + [@] + [체]와 같이 파편화(Fragmentation)된 형태로 인식하게 된다. 이로 인해 모델은 해당 단어가 내포하고 있던 '행정 기관'이라는 의미 정보를 상실하게 되고, 단순히 무의미한 글자의 나열로 처리하게 되어 질문에 대한 올바른 정답을 추론할 수 없게 된다.

EM 또한 71.99%에서 36.65%로 하락하여 F1 Score와 유사한 경향을 보였으며, 이는 구문적 오류가 누적될수록 정답의 정확한 위치를 특정하는 능력 또한 비례하여 상실됨을 시사한다.


결론: 구문 정확성 저하는 모델 성능에 예상보다 훨씬 치명적인 영향을 미치며, 특히 오염도가 높아질수록 성능 하락폭이 가팔라지는 경향을 보인다. 이는 최신 LLM이 아무리 고도화된 아키텍처를 갖추더라도, 데이터의 노이즈로 인해 입력 단계인 토큰라이저가 정상적으로 작동하지 못하면 성능을 담보할 수 없음을 증명한다. 따라서 데이터 구축 시 단순 수집을 넘어, 토큰라이징을 방해하는 특수문자나 오타자를 사전에 제거하는 정제 과정이 모델의 학습 효율을 보장하는 필수적인 선결 과제임을 확인하였다.

4.3 라벨링 정확성 저하에 따른 성능 변화

가설: 정답 텍스트(Label)에 오타자나 특수문자가 삽입될 경우, 토큰라이저가 정답을 올바른 의미 단위로 분해하지 못하게 된다. 이는 모델이 학습해야 할 정답의 토큰 구성 자체를 왜곡시키므로, 입력 데이터에서의 오류(지문/질문)보다 훨씬 심각한 성능 저하가 발생할 것으로 예상된다.

실험 결과:

	F1	EM
baseline	81.41	71.99
insertion_ans_10	28.29	19.68
insertion_ans_20	24.35	17.17
insertion_ans_30	10.02	6.90



분석: 라벨링 정확성 훼손은 세 가지 품질 저하 요인 중 가장 파괴적인 성능 저하를 초래하였다. 오염 비율이 10%에 불과한 시점에서도 F1 Score는 28.29%로 급락하여 대조군(81.41%) 대비 무려 53.12%나 폭락하였으며, 오염도가 30%에 이르면 F1 Score 10.02%를 기록하여 사실상 모델로서의 기능을 상실하였다. 이는 구문 정확성 저하의 최대 하락폭(-37.12%)이나 데이터 결측의 최대 하락폭(-3.56%)과 비교했을 때 압도적으로 높은 수치이며, 라벨링 오류가 모델 학습에 얼마나 치명적인지를 단적으로 보여준다고 할 수 있다.


이러한 결과의 주된 원인은 정답 라벨의 오염이 모델의 학습 목표 자체를 왜곡시켰기 때문이다. 지문이나 질문의 오류(입력 노이즈)는 모델이 정답을 찾는 과정을 어렵게 만들 뿐 정답 자체는 유효하지만, 라벨의 오류는 모델이 맞춰야 할 '정답'을 무의미한 의미 단위의 합으로 변질시킨다.


예를 들어, 정답인 '지방자치단체'가 '지!방자#치단체'로 오염될 경우, 토큰라이저는 이를 [지방] + [자치] + [단체]라는 의미 있는 서브워드(Subword)가 아닌, [지] + [!] + [방] + [자] + [#] + [치] + [단체]와 같이 파편화된 토큰의 나열로 인식한다. 모델은 문맥상 적절한 답변을 찾는 대신, 의미 없는 특수문자와 글자의 조합을 정답으로 학습해야 하는 상황에 빠지게 되며, 결과적으로 학습 방향성을 완전히 상실하게 된다.

특히 정답과의 일치 여부를 판별하는 EM 지표는 30% 오염 시 6.90%까지 추락하여 대조군(71.99%)의 1/10 수준에도 미치지 못하였다. 이는 정답 라벨에 노이즈가 약간이라도 포함될 경우, 모델이 정답을 추출하는 것 자체가 수학적으로 불가능해짐을 시사한다.

결론: 라벨링 정확성 훼손은 모델 성능에 회복 불가능한 치명적인 영향을 미친다. 지문이나 질문의 오류는 추론 능력의 저하를 야기하는 수준에 그치지만, 정답 라벨의 오류는 학습의 목표와 기준 자체를 파괴한다. 따라서 데이터 구축 및 품질 관리 과정에서 정답 라벨의 무결성 검증에 최우선적인 자원을 투입해야 함을 실험적으로 입증하였다.

4.4 종합 비교 분석





본 실험을 통해 세 가지 데이터 품질 저하 요인이 모델 성능(F1 Score)에 미치는 영향을 정량적으로 비교 분석하였다. Baseline(81.4%) 대비 오염 비율 30% 시점의 성능 하락폭은 다음과 같다.

라벨링 정확성 (Insertion_Ans): -71.4% (81.4% → 10.0%)

구문 정확성 (Insertion_Que): -37.1% (81.4% → 44.3%)

데이터 결측률 (Deletion): -3.6% (81.4% → 77.8%)

실험 결과, 데이터 품질 저하의 치명도는 라벨링 정확성 > 구문 정확성 > 데이터 결측률 순으로 나타났다. 특히 라벨링 정확성의 훼손은 모델 학습 자체를 불가능하게 만드는 가장 치명적인 요인임이 입증되었다. 또한, 기존 가설과 달리 구문 정확성 저하 또한 30% 수준의 고강도 노이즈 환경에서는 BERT의 강건성을 무력화시키며 상당한 성능 저하(-37.1%)를 야기함을 확인하였다. 반면, 데이터 결측은 30%의 정보가 소실되어도 성능 하락폭이 3.6%에 불과하여, 모델이 부분적인 문맥 정보만으로도 정답을 추론하는 높은 강건성을 보임을 확인하였다.

따라서 한정된 자원 하에서의 품질 관리 우선순위는 "정답(Label) > 질문/지문 노이즈(Noise) > 정보 누락(Missing)" 순으로 설정하는 것이 타당하고 할 수 있다.

5.1 실무 환경에서 자원 배분에 대한 고찰

본 연구는 LLM 학습용 데이터셋 구축 시, 데이터의 유형(정답, 질문, 지문)에 따라 노이즈가 모델 성능에 미치는 영향이 비대칭적임을 실증적으로 확인하였다. 이러한 실험 결과는 한정된 자원과 인력을 활용하여 데이터 품질을 최적화해야 하는 실무 환경에서 다음과 같은 기술적·전략적 시사점을 제공한다.

첫째, 정답(Answer) 데이터의 무결성은 모델 성능을 결정짓는 가장 결정적인 요소로 분석된다. 실험 결과, 정답 데이터의 10%에 노이즈가 포함될 경우 F1 Score는 28.3%까지 급격히 하락하였다. 이는 정답 텍스트가 지문이나 질문에 비해 길이는 짧지만, 핵심 정보가 고도로 압축된 영역이자 모델이 목표로 하는 라벨(Ground Truth)이기 때문이다. 정답에서의 오타자는 단순한 텍스트 오류를 넘어 학습 목표값 자체를 왜곡시키므로, 다른 데이터 유형에 비해 노이즈 민감도가 극도로 높게 나타난 것으로 해석된다. 따라서 데이터 구축 단계에서 정답 텍스트는 기계적 검증을 넘어 사람에 의한 전수 검증과 같은 고강도 품질 관리가 필수적으로 요구되는 영역임을 알 수 있다.

둘째, 질문(Question) 데이터는 사용자의 검색 의도를 포함하고 있어, 구문적 정확성이 모델의 추론 능력에 직접적인 영향을 미치는 것으로 확인되었다. 질문 내 구문 오류가 성능을 37.1% 하락시킨 실험 결과는, 질문 텍스트가 정답 탐색의 '트리거' 역할을 하기 때문으로 풀이된다. 편집 거리(Edit Distance) 1 수준의 미세한 오류라도 토큰라이저가 핵심 키워드가 다른 토큰으로 분리되게 하여 모델이 문맥적 연결고리를 상실하게 만드는 원인이 된다. 이는 질문 데이터 검증 시 육안 검사뿐만 아니라 문법적 정합성을 보장할 수 있는 자동화된 전처리 파이프라인의 도입이 중요함을 시사한다.

셋째, 지문(Context) 데이터는 정보의 중복성(Redundancy)으로 인해 노이즈에 대한 강건성이 상대적으로 가장 강한 영역임이 입증되었다. 지문 정보의 30%가 유실된 상황에서도 성능 하락폭이 -3.6%에 그친 결과는, 모델이 삭제된 단어 외의 주변 문맥을 활용하여 충분히 정답을 추론할 수 있음을 보여준다. 즉, 지문은 정보 밀도가 낮고 단서가 분산되어 있어 결측에 둔감하므로, 전수 조사를 통해 모든 텍스트를 완벽하게 보존하려는 시도보다는 샘플링 검수 방식이나 알고리즘 기반 검수 방식이 비용 효율성 측면에서 타당함을 알 수 있다.

종합적으로, 본 연구의 결과는 모든 데이터 유형에 동일한 수준의 품질 관리를 적용하는 것이 비효율적임을 시사하며, 데이터 유형별 민감도(정답 > 질문 > 지문)에 따른 '선별적 자원 배분 전략'의 필요성을 뒷받침한다. 모델 학습에 치명적인 영향을 주는 정답과 질문에는 검증 자원을 집중하고, 상대적으로 강건한 지문에는 유연한 검수 기준을 적용하는 것이 전체 프로젝트의 ROI(투자 대비 효과)를 극대화하는 방안이 될 것이다. 이러한 차등적 접근은 데이터 구축 예산의 낭비를 방지하면서도 실질적인 모델 성능 향상을 담보하는 최적의 균형점으로 판단된다.

5.2 연구의 한계 및 향후 연구 방향

본 연구는 기계독해(MRC) 태스크와 KLUE-BERT 단일 모델에 국한된 실험 결과라는 점에서, GPT나 LLaMA와 같은 최신 생성형 모델(Generative Models) 및 요약, 번역 등 다양한 자연어 처리 과제로의 일반화 가능성을 추가적으로 검증해야 하는 한계를 가지고 있다. 또한, 무작위 특수문자 삽입이나 삭제를 통한 오염 시나리오는 실제 데이터 구축 현장에서 발생하는 복합적이고 의미적인 휴먼 에러나 편향을 완벽히 모사하는 데 한계가 있으므로, 향후에는 보다 정교하고 현실적인 노이즈 모델링이 요구된다. 아울러 본 실험은 품질 저하 요인을 개별적으로 통제하여 분석하였으나, 실제 환경에서는 결측과 오타자 등 여러 오류가 동시다발적으로 발생할 수 있다는 점을 고려할 때, 향후 연구에서는 다중 요인이 복합적으로 작용할 때 발생하는 상호작용 효과(Interaction Effect)에 대한 심층적인 분석이 수반되어야 할 것이다.

5.5 결론

본 연구는 기계독해 모델의 학습 효율을 결정짓는 데이터 품질 관리의 우선순위가 정답 > 입력 질문 > 입력 지문 의 위계를 따름을 실증적으로 규명하였다. 특히 정보 밀도가 높은 데이터일수록 모델이 노이즈에 치명적임을 보여주었다. 학습의 목표가 되는 '정답 라벨'은 미세한 오타자만으로도 토큰나이징 단계의 서브워드 파편화를 유발하여 모델의 성능을 치명적인 수준으로 손상시켰으며, 이는 정답의 무결성이 타협할 수 없는 최우선 관리 대상임을 시사한다. 반면, 정보의 중복성이 높은 지문(Context) 데이터는 30%의 물리적 결측에도 성능을 77.85% 수준으로 방어해내는 강건함을 입증하였다. 결론적으로, 성공적인 AI 데이터 구축을 위해서는 모든 데이터를 완벽하게 만들려는 기계적인 접근에서 벗어나 데이터 유형별 민감도에 따라 검증 자원을 차등 배분하는 '선택과 집중' 전략을 통해 프로젝트의 실질적인 ROI를 극대화하는 합리적인 품질 관리 체계를 확립해야 할 것이다.